天津大学

编译原理大作业

开发报告&测试报告

学　　院　　智能与计算学部

专　　业　　计算机科学与技术

姓名学号　　贾天玉（3019244416）

刘梦迪（3019244420）

王志鸣（3019244395）

李德新（3019244351）

指导教师　　陈俊洁、刘爽老师

2022 年 5 月 7 日

SQL_compiler

TJU编译原理大作业——词法分析器与语法分析器设计

目录结构

```
SQL_COMPLIER
 |-lexical-analysis
    |-input
      |-testOA.sql
      |-testOB.sql
    |-output
      |-13Alex.tsv
      |-13Blex.tsv
    |-NFA.py
    |-NFAtoDFA.py
    |-DFAtoMFA.py
    |-lexer.py
    |-main.py
    |-README.md
 |-synatax-annalysis
    |-input
      |-OAlex.tsv
      |-OBlex.tsv
    |-output
      |-13Agra.tsv
      |-13Bgra.tsv
    |-LL.py
    |-LR.py
    |-sql_syntax.txt
    |-README.md
 |-README.md
```

开发环境

- windows
- python

一、词法分析器设计

（一） 开发报告

1 实现路径

1.1 实现思路

1. 根据实验指导书的单词符号**构造出对应的NFA。**
2. 编写**确定化、最小化算法**将构造的NFA自动转换成DFA。
3. 编写词法分析器的类执行词法分析。

1.2 需要实现的单词符号

在下表中列出需要实现的**单词符号**

关键字（KW）

类别	语法关键词
查询关键词	(1) SELECT, (2) FROM, (3) WHERE, (4) AS, (5) *
插入表达式	(6) INSERT, (7) INTO, (8) VALUES, (9) VALUE, (10) DEFAULT
更新表达式	(11) UPDATE, (12) SET
删除表达式	(13) DELETE
连接操作	(14) JOIN, (15) LEFT, (16) RIGHT, (17) ON
聚合操作	(18) MIN, (19) MAX, (20) AVG, (21) SUM
集合操作	(22) UNION, (23) ALL
组操作	(24) GROUP BY, (25) HAVING, (26) DISTINCT, (27) ORDER BY
条件语句	(28) TRUE, (29) FALSE, (30) UNKONWN, (31) IS, (32) NULL

运算符（OP）

运算符类型	语法关键词
比较运算符	(1) =, (2) >, (3) <, (4) >=, (5) <=, (6) !=, (7) <=>
逻辑运算符	(8) AND, (9) &&, (10) OR, (11) ||, (12) XOR, (13) NOT, (14) !
算数运算符	(15) -
属性运算符	(16) .

界符（SE）

类型	语法关键词
界符	(1) (, (2)), (3) ,

标识符（IDN） 以字母、数字和下划线（_）组成的不以数字开头的串

整数（INT）、浮点数（FLAOT）与C语言相同定义

字符串（STRING）使用**双引号**包含的任意字符串

2 算法描述

2.1 确定化算法

1. 首先从s_0出发，仅经过任意条ϵ箭弧能够到达的状态组成的集合I作为M'的初态q_0 .
2. 分别把从q_0(对应于M的状态子集I)出发，经过任意$a \in \sum$的a弧转换I_a所组成的集合作为M'的状态，如此继续，直到不再有新的状态为止。

2.2 最小化算法

$DFAM = (S, \sum, \sigma, s_0, S_t)$,最小状态$DFAM'$

1. 构造状态的初始划分$\prod$：终态S_t和非终态$S - S_t$两组
2. 对$\prod$施用传播性原则构造新划分$\prod_{new}$
3. 如$\prod_{new} == \prod$，则令$\prod_{final} == \prod$并继续步骤4，否则$\prod := \prod_{new}$重复2
4. 为$\prod_{final}$中的每一组选一代表，这些代表构成M'的状态。若s是一代表，且$\sigma(s, a) = t$，令r是t组的代表，则M'中有一转换$\delta'(s, a) = r$。M'的开始状态是含有s_0的那组的代表，M'的终态是含有s_t的那组的代表。
5. 去掉M'中的死状态。

2.3 状态转化图

如下图:

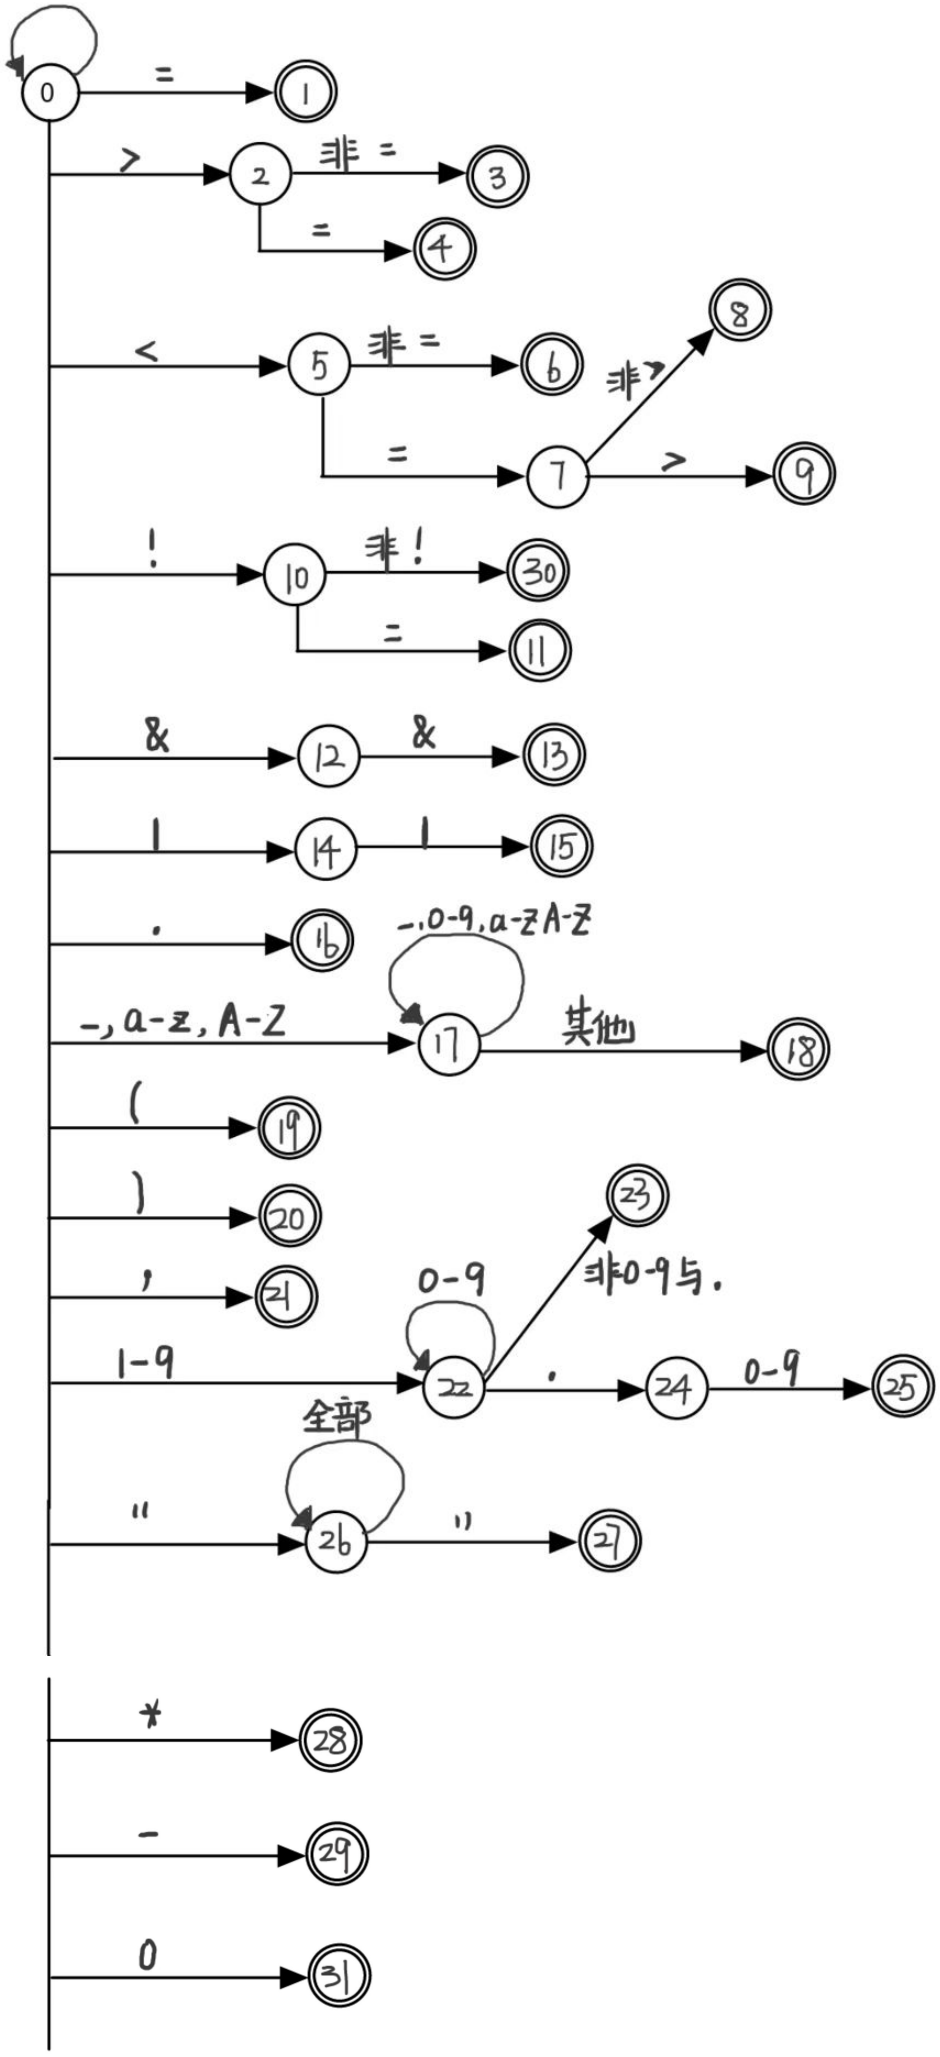
0
=
1
>
2
非=
3
=
4
<
5
非=
6
=
7
非>
8
>
9
!
10
非!
30
=
11
&
12
&
13
|
14
|
15
.
16
-,0-9,a-zA-Z
-,a-z,A-Z
17
其他
18
(
19
)
20
,
21
0-9
23
非0-9与.
1-9
22
.
24
0-9
25
全部
"
26
"
27
*
28
-
29
0
31

3 算法实现

运用**面向对象**的编程思想，将NFA,DFA和词法分析器等抽象成一个个类。

由简到繁，先将类的定义规划好，再逐渐扩充完善细节。

3.1 NFA的定义与实现

根据NFA定义依据五元组$M = (S, \sum, \sigma, S_0, F)$构造成一个**类**，使用面向对象的编程方式来进行词法分析器的编写。

定义的类：

1. **Node**

   表示NFA中的一个节点，DFA中的节点定义并无区别，所以仍然使用该`class`

   - `id`是节点的编号；
   - `isFinal`用来判断是否是终止节点；
   - `isBackoff`用来判断是否需要回退；
   - `tag`用于判定最终得到的token类别。

```
class Node:
    def __init__(self, id, is_final, is_back_off, tag):
        # id
        self.id = id
        # 是否是终结节点 1代表是，0代表不是
        self.isFinal = is_final
        # 是否需要回退 1代表需要，0代表不需要
        self.isBackOff = is_back_off
        # 只有终结节点需要tag
        self.tag = tag
```

2. **Edge**

   表示NFA中的边。

   要注意的是由于是`NFA`，所以同一个`tag`可以去往多个不同的节点，因此这里`toNodeIds`使用的是`set`的数据结构，用来存放多个可能的节点。

   - `fromNodeId`表示有向边的出发节点；
   - `tag`表示获得`tag`可以从`fromNodeId`转化为`toNodeIds`；
   - `toNodeIds`使用集合表示通过`tag`可以抵达的节点集合。

```
class Edge:
    def __init__(self, from_node_id, to_node_id: set, tag):
        # from 节点
        self.fromNodeId = from_node_id
        # to 节点 同一个tag可以去到的所有节点集合
        self.toNodeIds = to_node_id
        # 转化需要的信息，使用正则表达式表示
        self.tag = tag
```

3. **NFA**

依据绘制的NFA状态转化图进行初始化。

属性：

- `nodes`数组中元素类型为`class Node`
- `edges`数组中元素类型为`class Edge`
- `nowId`代表当前状态机指向的位置；
- `startId`代表初始节点的`id`(与`node`的`id`属性对应)

函数：

- `add_node`：添加节点至`nodes`
- `add_edges`：添加节点至`edges`
- `get_start`:将指针指向开始节点
- `is_final`：判定当前指针是否在**终止节点**
- `is_back_off`：判定是否需要退出一个字符
- `get_tag`：获得`node`的tag

```
class NFA:
    def __init__(self):
        # 存放节点
        self.nodes = []
        self.edges = []
        # 当前状态机所在的位置
        self.nowId = 0
        # 开始节点
        self.startId = 0

        # 初始化nodes和edges
        # OP
        self.add_node(0, 0, 0, "")
        self.add_node(1, 1, 0, "OP")
        self.add_node(2, 0, 0, "")
        self.add_node(3, 1, 1, "OP")
        self.add_node(4, 1, 0, "OP")
        self.add_node(5, 0, 0, "")
        self.add_node(6, 1, 1, "OP")
        self.add_node(7, 0, 0, "")
        self.add_node(8, 1, 1, "OP")
        self.add_node(9, 1, 0, "OP")
        self.add_node(10, 0, 0, "")
        self.add_node(11, 1, 0, "OP")
        # self.add_node(12, 0, 0, "")
        # self.add_node(13, 0, 0, "")
        # self.add_node(14, 1, 0, "AND")
        self.add_node(12, 0, 0, "")
        self.add_node(13, 1, 0, "OP")
        self.add_node(14, 0, 0, "")
        self.add_node(15, 1, 0, "OP")
        self.add_node(16, 1, 0, "OP")
        # 标识符IDN
        self.add_node(17, 0, 0, "")
        self.add_node(18, 1, 1, "IDNorKWorOP")
```

```
        # 界符 SE
        self.add_node(19, 1, 0, "SE")
        self.add_node(20, 1, 0, "SE")
        self.add_node(21, 1, 0, "SE")
        # 整数、浮点数
        self.add_node(22, 0, 0, "")
        self.add_node(23, 1, 1, "INT")
        self.add_node(24, 0, 0, "")
        self.add_node(25, 1, 1, "FLOAT")
        # 字符串
        self.add_node(26, 0, 0, "")
        self.add_node(27, 1, 0, "STRING")

        # 后续补充的节点
        self.add_node(28, 1, 0, "IDNorKWorOP")
        self.add_node(29, 1, 0, "OP")
        self.add_node(30, 1, 1, "OP")
        # 0
        self.add_node(31, 1, 0, "INT")

        # 添加边的信息
        # 部分OP到 <=>为止
        self.add_edges(0, {0}, " ")
        self.add_edges(0, {1}, "=")
        self.add_edges(0, {2}, ">")
        self.add_edges(2, {3}, "[^=]")
        self.add_edges(2, {4}, "=")
        self.add_edges(0, {5}, "<")
        self.add_edges(5, {6}, "[^=]")
        self.add_edges(5, {7}, "=")
        self.add_edges(7, {8}, "[^>]")
        self.add_edges(7, {9}, ">")
        self.add_edges(0, {10}, "!")
        self.add_edges(10, {11}, "=")

        self.add_edges(0, {12}, "&")
        self.add_edges(12, {13}, "&")
        self.add_edges(0, {14}, "[\|]")
        self.add_edges(14, {15}, "[\|]")

        self.add_edges(0, {16}, "[\.]")

        # 标识符和keyword
        self.add_edges(0, {17}, "[_a-zA-Z]")
        self.add_edges(17, {17}, "[_0-9a-zA-Z]")
        self.add_edges(17, {18}, "[^_0-9a-zA-Z]")

        self.add_edges(0, {19}, "[(]")
        self.add_edges(0, {20}, "[)]")
        self.add_edges(0, {21}, ",")

        # int, float
        self.add_edges(0, {22}, "[1-9]")
        self.add_edges(22, {22}, "[0-9]")
        self.add_edges(22, {23}, "[^\.0-9]")
```

```
        self.add_edges(22, {24}, "[\.]")
        self.add_edges(24, {24}, "[0-9]")
        self.add_edges(24, {25}, "[^0-9]")

        # string
        self.add_edges(0, {26}, "[\"\']")
        self.add_edges(26, {26}, ".")
        self.add_edges(26, {27}, "[\"\']")

        # 后续补充的边
        self.add_edges(0, {28}, "[\*]")
        self.add_edges(0, {29}, "-")
        self.add_edges(10, {30}, "[^!]")

        # debug发现的
        self.add_edges(0, {31}, "[0]")

    # 添加节点
    def add_node(self, id, is_final, is_back_off, tag):
        new_node = Node(id, is_final, is_back_off, tag)
        self.nodes.append(new_node)

    # 添加边
    def add_edges(self, from_node_id, to_node_ids: set, tag):
        new_edge = Edge(from_node_id, to_node_ids, tag)
        self.edges.append(new_edge)

    # 将指针指向开始节点
    def get_start(self):
        self.nowId = self.startId

    # 是否结束
    def is_final(self, id):
        # 因为是按照顺序添加的节点,所以nodes的下标对应着一样的id
        return self.nodes[id].isFinal

    # 是否需要退出一个字符
    def is_back_off(self, id):
        return self.nodes[id].isBackOff

    # 获得tag
    def get_tag(self, id):
        # 可以根据tag返回需要的内容
        return self.nodes[id].tag
```

3.2 DFA的定义与实现

基于已经实现的NFA，通过确定化算法和最小化算法，得到DFA。

定义的类：

1. **DFAEdge**

   与Edge的定义类似，不同点在于`toNodeIds`的定义。`DFA`中通过一个`tag`只能抵达一个确定的`node`，所以在`DFAEdge`中`toNodeIds`是一个`int`类型数据。

   - `fromNodeId`表示有向边的出发节点；
   - `tag`表示获得`tag`可以从`fromNodeId`转化为`toNodeIds`；
   - `toNodeIds`使用集合表示通过`tag`可以抵达的节点。

```
class DFAEdge:
    def __init__(self, from_node_id, to_node_id: int, tag):
        # from 节点
        self.fromNodeId = from_node_id
        # to 节点 同一个tag可以去到的所有节点集合
        self.toNodeIds = to_node_id
        # 转化需要的信息
        self.tag = tag
```

2. **DFA**

通过已有的NFA进行确定化和最小化算法生成DFA。

属性：

- `nodes`数组中元素类型为`class Node`
- `edges`数组中元素类型为`class DFAEdge`
- `nowId`代表当前状态机指向的位置；
- `startId`代表初始节点的`id`(与`node`的`id`属性对应)

函数：

- `epsilon_closure`：计算闭包
- `move`：计算move集合
- `determine`：确定化算法
- `add_node`：添加节点至`nodes`
- `add_edges`：添加节点至`edges`

```
class DFA:
    def __init__(self):
        # 存放节点
        self.nodes = []
        self.edges = []
        # 当前状态机所在的位置
        self.nowId = 0
        # 开始节点
        self.startId = 0

        # 确定化将NFA转化为DFA，将nodes和edges填上
        # self.determine(nfa)


    @staticmethod
    # e-closure计算
```

```
    def epsilon_closure(self, node_set: set, nfa: NFA):
        # 查找node_set经过任意条epsilon弧能抵达的节点们
        edges = nfa.edges

        # 用于判断是否已经出现过了
        node_id_set = set()
        # 获得所有的node的id
        for node in node_set:
            node_id_set.add(node.id)

        for node in node_set:
            node_id = node.id
            for edge in edges:
                if edge.tag == "epsilon" and edge.fromNodeId == node_id:
                    # 如果新的node不在node_set中则加入，否则跳过
                    # 遍历所有的可以抵达的node
                    for toNodeId in edge.toNodeIds:
                        if toNodeId in node_id_set:
                            continue
                        else:
                            # 将能够抵达的node加入new_node_set
                            node_set.add(nfa.nodes[toNodeId])

        return node_set

    @staticmethod
    def move(self, node_set: set, nfa: NFA, tag):

        edges = nfa.edges
        # 返回的全新node集合
        new_node_set = set()
        # 用于判断是否已经出现过了
        node_id_set = set()
        # # 获得所有的node的id
        # for node in node_set:
        #     node_id_set.add(node.id)

        # 遍历每一个node
        for node in node_set:
            for edge in edges:
                # 相同tag的匹配
                if edge.fromNodeId == node.id and edge.tag == tag:
                    for toNodeId in edge.toNodeIds:
                        if toNodeId in node_id_set:
                            continue
                        else:
                            new_node_set.add(nfa.nodes[toNodeId])
        return new_node_set

    # 确定化算法
    def determine(self, nfa: NFA):
        self.nodes = []

        # 先计算nfa的起始节点的闭包
        start_node = nfa.nodes[nfa.startId]
```

```
        # new_start_node_set = self.epsilon_closure(self, {start_node}, nfa)
        new_start_node_set = {start_node}

        # 初始化将初始点加入集合中
        node_queue = [new_start_node_set]
        now_id = 0
        self.add_node(now_id, 0, 0, "")

        # 因为是按照顺序进入的，所以point和from_node_id是相同的
        point = 0
        while point < len(node_queue):
            # 取出队列中未计算的最靠前的set
            node_set = node_queue[point]
            # 对每一个tag进行move计算
            for tag in tags:
                move_node_set = self.move(self, node_set, nfa, tag)
                # 如果是空则忽略
                if len(move_node_set) == 0:
                    continue
                # 非空且未出现过需要连接edge，并添加node
                elif not (move_node_set in node_queue):
                    # 先加入队列，用于继续计算
                    node_queue.append(move_node_set)
                    # 对DFA处理node和edges

                    # 从move_node_set中的第一个节点获得is_final 和 is_back_off
                    is_final = 0
                    is_back_off = 0
                    # 获得一个isFinal, isBackOff
                    node_tag = ""
                    for one in move_node_set:
                        is_final = one.isFinal
                        is_back_off = one.isBackOff
                        node_tag = one.tag
                        break
                    now_id += 1
                    # self.add_node(now_id, is_final, is_back_off, tag)
                    # print(now_id, is_final, is_back_off, node_tag)
                    self.add_node(now_id, is_final, is_back_off, node_tag)
                    self.add_edges(point, now_id, tag)
                # 非空但出现过只需要连接edge
                else:
                    # 计算to_node_id，就是在node_queue中的index
                    to_node_id = node_queue.index(move_node_set)
                    self.add_edges(point, to_node_id, tag)
            point += 1
        # for i in self.edges:
        #     print('fromId:'+str(i.fromNodeId)+' tag:'+str(i.tag)+' toNodeId:
'+str(i.toNodeIds))

    # 添加节点
    def add_node(self, id, is_final, is_back_off, tag):
        new_node = Node(id, is_final, is_back_off, tag)
        self.nodes.append(new_node)
```

```
    # 添加边
    def add_edges(self, from_node_id, to_node_id: int, tag):
        new_edge = DFAEdge(from_node_id, to_node_id, tag)
        self.edges.append(new_edge)
```

3.3 DFA的最小化

定义的类：

DFAtoMFA

属性与DFA类似，只是增加了一个dfa的属性，dfa为最小化之前的DFA。

属性：

- `dfa` 代表最小化之前的DFA
- `nodes` 数组中元素类型为 `class Node`
- `edges` 数组中元素类型为 `class DFAEdge`
- `nowId` 代表当前状态机指向的位置；
- `startId` 代表初始节点的 `id` (与 `node` 的 `id` 属性对应)

函数：

- `getToNode` :从 node 经过 tag 转移能到达的所有状态的集合
- `build` :构造MFA
- `add_node`：添加节点至 `nodes`
- `add_edges`：添加节点至 `edges`
- `get_start`：将指针指向开始节点
- `is_final`：判定当前指针是否在**终止节点**
- `is_back_off`：判定是否需要退出一个字符
- `get_tag`：获得 `node` 的tag
- `next_id`：通过得到的 `ch` 获得一个 `node` 的 `id`
- `get_token_type`：根据给出的 `token` 判断类型，用于输出
- `get_token_num`：根据给出的 `token` 判定编号，用于输出
- `getnewDfa` :根据新的节点ID和最小化之前的节点ID对应关系构造新的DFA

```
class DFAtoMFA: #DFA最小化
    def __init__(self,dfa):
        self.dfa = dfa
        # 存放节点
        self.nodes = []
        self.edges = []
        # 当前状态机所在的位置
        self.nowId = 0
        # 开始节点
        self.startId = 0
        self.buildMFA()

    #  从 node 经过 tag 转移能到达的所有状态的集合
    def getToNode(self,nodeId,tag):
        for i in self.dfa.edges:
            if(i.fromNodeId == nodeId and i.tag == tag):
                return i.toNodeIds
```

```
        return 100

    def buildMFA(self):
        # 如果只有一个节点，那它本身为MFA
        if len(self.dfa.nodes) <= 1:
            self.mfa = self.dfa
            return
        finalNoBackNodesOP = [] # 存储终态并且不会回退的节点的编号
        finalNoBackNodesSE = []
        finalNoBackNodesID = []
        finalNoBackNodesSTR = []

        finalBackNodesOP = [] #存储终态并且会回退的节点的编号
        finalBackNodesID = []
        finalBackNodesINT = []
        finalBackNodesFL = []

        noFinalNodes = []
        nodeIds = [] #存储所有节点的Id
        for i in self.dfa.nodes:
            nodeIds.append(i.id)
            if i.isFinal == 1 and i.isBackOff == 1 :
                if i.tag == 'OP':
                    finalBackNodesOP.append(i.id)
                if i.tag == 'IDNorKWorOP':
                    finalBackNodesID.append(i.id)
                if i.tag == 'INT':
                    finalBackNodesINT.append(i.id)
                if i.tag == 'FLOAT':
                    finalBackNodesFL.append(i.id)

            if i.isFinal == 1 and i.isBackOff == 0 :
                if i.tag == 'OP':
                    finalNoBackNodesOP.append(i.id)
                if i.tag == 'SE':
                    finalNoBackNodesSE.append(i.id)
                if i.tag == 'IDNorKWorOP':
                    finalNoBackNodesID.append(i.id)
                if i.tag == 'STRING':
                    finalNoBackNodesSTR.append(i.id)

            if i.isFinal == 0:
                noFinalNodes.append(i.id)
        pos = dict(zip(nodeIds,range(len(nodeIds))))#pos 中存储每一个节点对应处于的集合编号  一直处于不断地变化中
        pos[100] = 9

        set1 = set(finalBackNodesOP)
        set2 = set(finalBackNodesID)
        set3 = set(finalBackNodesINT)
        set4 = set(finalBackNodesFL)

        set5 = set(finalNoBackNodesID)
        set6 = set(finalNoBackNodesOP)
        set7 = set(finalNoBackNodesSE)
```

```
        set8 = set(finalNoBackNodesSTR)

        set9 = set(noFinalNodes)

        set1 = list(set1)
        set2 = list(set2)
        set3 = list(set3)
        set4 = list(set4)
        set5 = list(set5)
        set6 = list(set6)
        set7 = list(set7)
        set8 = list(set8)
        set9 = list(set9)

        for i in set1:
            pos[i] = 0
        for i in set2:
            pos[i] = 1
        for i in set3:
            pos[i] = 2
        for i in set4:
            pos[i] = 3
        for i in set5:
            pos[i] = 4
        for i in set6:
            pos[i] = 5
        for i in set7:
            pos[i] = 6
        for i in set8:
            pos[i] = 7
        for i in set9:
            pos[i] = 8

        allsets = [set1,set2,set3,set4,set5,set6,set7,set8,set9]
        counts = 10
        flag = True
        while flag:
            flag = False
            for char in tags:
                for sub_set in allsets:
                    dic = dict() # 存储节点和新对应的编号
                    lists = []
                    # 找出某个set中通过某个tag能够到达的所有节点
                    for oneNode in sub_set:
                        num = self.getToNode(oneNode,char)
                        num = pos[num] #获取转移状态对应的集合编号
                        # print(num)

                        if num not in  dic.keys():   #如果没有建立 该状态对应的集合编
号  的字典关系  新建
                            dic[num] =counts
                            counts+=1
                        lists.append(dic[num])
                    if len(lists) == 0:
                        continue
```

```
                    # print(lists)

                    if len(dic) >1: #证明该集合中状态转移 不是转移到同一处 拆分元素 跳出循环
                        flag = True
                        tmp_set=dict()   #新编号与新数值相对应  加入不同的新list
                        for i1 in range(len(sub_set)):
                            if lists[i1] not  in tmp_set.keys():
                                tmp_set[lists[i1]]=list()
                            tmp_set[ lists[i1] ].append(sub_set[i1])
                            pos[sub_set[i1]] = lists[i1] #更新pos  更新状态 所在的集合的编号

                        allsets.remove(sub_set) #将旧的list移除
                        for i1 in tmp_set.values(): #将新的list 加入
                            allsets.append(i1)
                        break

                if flag == True:
                    break


        for i in range(len(allsets)):    #计算出每个数值对应的新的数值
            for j in allsets[i]:
                pos[j] =i+1

        # print(pos)
        # print(set1)
        pos.pop(100)
        # print(pos)
        # for i in self.dfa.nodes:
        #     print('id: ' + str(i.id) + 'isBackOff: ' + str(i.isBackOff))



        self.getnewDfa(pos,self.dfa)


    # 添加节点
    def add_node(self, id, is_final, is_back_off, tag):
        new_node = Node(id, is_final, is_back_off, tag)
        self.nodes.append(new_node)

    # 添加边
    def add_edges(self, from_node_id, to_node_id: int, tag):
        new_edge = DFAEdge(from_node_id, to_node_id, tag)
        self.edges.append(new_edge)

    # 将指针指向开始节点
    def get_start(self):
        self.nowId = self.startId

    # 获得下一个ID
    def next_id(self, tag):
        for edge in self.edges:
```

```
            if edge.fromNodeId == self.nowId and re.match(edge.tag, tag):
                # 并将nowId指向新的位置
                self.nowId = edge.toNodeIds
                # 说明成功找到下一个节点
                return True
        return False

    def is_final(self, id):
        # 因为是按照顺序添加的节点,所以nodes的下标对应着一样的id
        for i in self.nodes:
            if i.id == id:
                return i.isFinal

    # 是否需要退出一个字符
    def is_back_off(self, id):
        for i in self.nodes:
            if i.id == id:
                return i.isBackOff

    # 获得tag
    def get_tag(self, id):
        # 可以根据tag返回需要的内容
        for i in self.nodes:
            if i.id == id:
                return i.tag
    def get_token_type(self, token, node_tag):
        # KW, OP, SE, IDN, INT, FLOAT, STR

        # OP, SE, INT, FLOAT,STR都可以直接判断
        if node_tag == "OP" or node_tag == "SE" or node_tag == "INT" or node_tag
== "FLOAT" or node_tag == "STRING":
            return node_tag
        elif node_tag == "IDNorKWorOP":
            keywords = TYPE_TO_CONTENT_DICT_KW.keys()
            ops = TYPE_TO_CONTENT_DICT_OP.keys()
            if token in keywords:
                return "KW"
            elif token in ops:
                return "OP"
            else:
                return "IDN"

    # 判断编号
    def get_token_num(self, token, token_type):
        if token_type == "IDN" or token_type == "INT" or token_type == "FLOAT"
or token_type == "STRING":
            return token
        elif token_type == "KW":
            return TYPE_TO_CONTENT_DICT_KW[token]
        elif token_type == "OP":
            return TYPE_TO_CONTENT_DICT_OP[token]
        elif token_type == "SE":
            return TYPE_TO_CONTENT_DICT_SE[token]

    def getnewDfa(self,dicts,dfa):
```

```
        self.startId = dicts[dfa.startId]
        # print(self.startId)

        addSets = [] # 存储加入新的DFA的节点
        # 在新的DFA加入节点
        for key,value in dicts.items():
            if value not in addSets:
                addSets.append(value)

 self.add_node(value,dfa.nodes[key].isFinal,dfa.nodes[key].isBackOff,dfa.nodes[k
ey].tag)
        addEdges = []
        for edge in dfa.edges:
            tup = (dicts[edge.fromNodeId],dicts[edge.toNodeIds],edge.tag)
            if tup not in addEdges:

 self.add_edges(dicts[edge.fromNodeId],dicts[edge.toNodeIds],edge.tag)
                addEdges.append(tup)
        # print('addSets: ' + str(addSets))
```

3.4 词法分析器Lexer

`Lexer`类的主要功能是通过读取`sql--`文件生成`token`序列，并进行输出。

支持打印在控制台和输出到文件中两种输出方式。

定义的类：

1. **Token**

   依据本次实验要求输出的格式进行定义。包含三个部分：

   - `lexeme`待测代码中的单词符号
   - `tokenType`单词符号种别
   - `tokenNum`单词符号内容

   ```
   class Token:
       def __init__(self, lexeme: str, token_type: str, token_num: str):
           self.lexeme = lexeme
           self.tokenType = token_type
           # 说是num，其实不是全是num，所以还是用str类型
           self.tokenNum = token_num
   ```

2. **TokenTable**

   定义了Token的输出方式。

   属性：

   - `tokens`一个保存`token`的数组

   方法：

   - `print_token_table`在控制台按照格式输出token列表
   - `save_token_table`保存输出到文件中。

   ```
   class TokenTable:
   ```

```
    def __init__(self):
        self.tokens = []

    def print_token_table(self):
        for token in self.tokens:
            print("{}   <{},{}>".format(token.lexeme, token.tokenType,
token.tokenNum))

    def push_token(self, token: Token):
        self.tokens.append(token)

    def save_token_table(self, path):
        f = open(path, "w+")
        for token in self.tokens:
            f.write("{}   <{},{}>\n".format(token.lexeme, token.tokenType,
token.tokenNum))
        f.close()
```

3. **Lexer**

   执行词法分析的主程序，需要提供一个`DFA`作为输出参数。会生成一个`tokenTable`类，保存输出的数据。

   方法：

   - `run`执行词法分析

```
class Lexer:
    def __init__(self, path: str, token_table: TokenTable, dfa: DFA):
        self.source = open(path, 'r').read()
        self.source += " "
        self.tokenTable = token_table
        self.dfa = dfa

    # 执行词法分析
    def run(self):
        # 流程：
        #   token_now = ""
        #   1.读取字符
        #   2.查找对应的状态转换
        #       2.1 如果找不到则说明错误的词法，报错
        #       2.2 如果找到了则状态转换到新的状态
        #           2.2.1 非终结态则继续读取
        #           2.2.2 终结态判断is_back_off
        #               2.2.2.1 true：从token_now退出一个ch,将生成的token_now加
入tokentable
        #               2.2.2.2 false: 将token_now加入token list中
        #           2.2.3 修改DFA的指针指向初始位置，token_now = ""

        # 初始化
        text = self.source
        token_now = ""
        self.dfa.get_start()
        ID = 0
        i = 0
```

```
        while i < len(text):
            # 需要跳过的情况
            ch = text[i]
            if token_now == "" and (ch == "\n" or ch == ' '):
                i += 1
                continue

            # GROUP BY和ORDER BY特殊处理
            if token_now == "GROUP" or token_now == "ORDER":
                i += 1
                token_now += " "
                continue

            token_now += ch
            # 匹配成功到下一个节点
            if self.dfa.next_id(ch):
                ID = self.dfa.nowId
                # 判断is_final
                if self.dfa.is_final(ID):
                    # 判断is_back_off
                    if self.dfa.is_back_off(ID):
                        # 指针回退一个
                        token_now = token_now[0:-1]
                        i -= 1

                    # 获得最终节点的tag
                    node_tag = self.dfa.get_tag(ID)
                    # 这个判断应该是dfa提供的
                    token_type = self.dfa.get_token_type(token_now,
node_tag)
                    token_num = self.dfa.get_token_num(token_now,
token_type)

                    self.tokenTable.push_token(Token(token_now, token_type,
token_num))
                    token_now = ""
                    self.dfa.get_start()
                i += 1
            # 匹配失败，则抛出异常
            else:
                print("Lexical error: 不符合sql词法！")
                return

        # 如果最后一个词是属于IDNorKWorOP那么也要加入token_list中

        if not self.dfa.is_final(ID):
            print("Lexical error: 最终一个词不是完整的token")
            return
```

4 输出格式说明

[待测代码中的单词符号] [TAB] <[单词符号种别],[单词符号内容]>

4.1 控制台中的打印格式

按照要求进行打印：

```
cr7   <IDN,cr7>
WHERE   <KW,3>
from_   <IDN,from_>
.   <OP,16>
_2_   <IDN,_2_>
>   <OP,2>
1   <INT,1>
AND   <OP,8>
from_   <IDN,from_>
.   <OP,16>
_3_   <IDN,_3_>
<   <OP,3>
3.1415926   <FLOAT,3.1415926>
OR   <OP,10>
1.25   <FLOAT,1.25>
IS   <KW,31>
NOT   <OP,13>
NULL   <KW,32>
GROUP BY   <KW,24>
from_   <IDN,from_>
.   <OP,16>
_2_   <IDN,_2_>
HAVING   <KW,25>
from_   <IDN,from_>
.   <OP,16>
_3_   <IDN,_3_>
=   <OP,1>
"ORDER BY #><=="   <STRING,ORDER BY #><==>
```

4.2 文件中的保存格式

按照要求进行保存：

```
SELECT    <KW,1>
from_    <IDN,from_>
.    <OP,16>
_1_    <IDN,_1_>
,    <SE,3>
SUM    <KW,21>
(    <SE,1>
from_    <IDN,from_>
.    <OP,16>
_2_    <IDN,_2_>
)    <SE,2>
FROM    <KW,2>
from_    <IDN,from_>
JOIN    <KW,14>
_1A    <IDN,_1A>
ON    <KW,17>
from_    <IDN,from_>
.    <OP,16>
_1_    <IDN,_1_>
=    <OP,1>
_1A    <IDN,_1A>
.    <OP,16>
```

5 源程序编译步骤

本词法分析器使用python实现，因此无需编译。

5.1 引入外部包

需要的外部包：

- `re`：正则表达式相关的包

5.2 根据需要修改main.py文件

- 修改`path`为`sql--`所在路径。
- 修改`main()`函数中的保存路径。

```
# 输出文件的保存路径
lexer.tokenTable.save_token_table("./test.txt")
```

- 直接执行`main.py`代码即可。

（二）测试报告

测试1

测试用例

```
INSERT INTO _tb1 VALUES (1,1.78,"SELECT")
```

词法分析结果

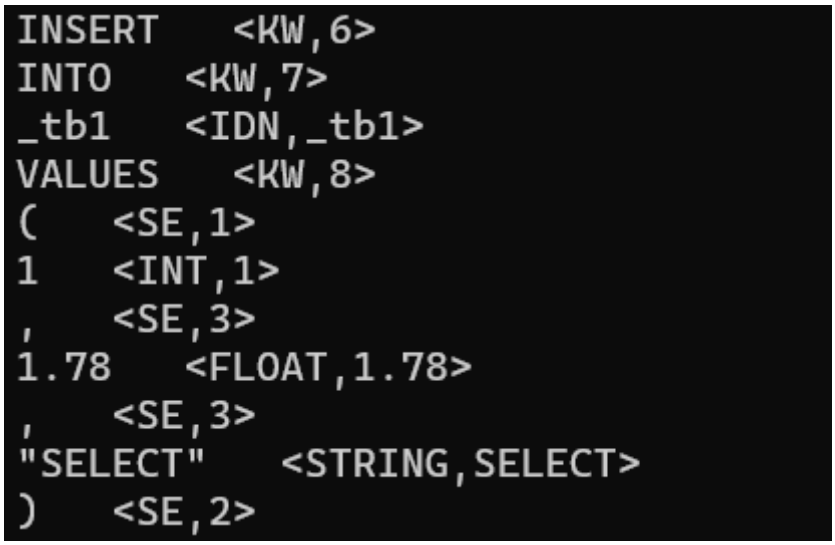

测试2

测试用例

```
SELECT from_._1_,SUM(from_._2_) FROM from_ JOIN _1A ON from_._1_=_1A.cr7 WHERE
from_._2_>1 AND from_._3_<3.1415926 OR 1.25 IS NOT NULL GROUP BY from_._2_
HAVING from_._3_="ORDER BY #><=="
```

词法分析结果

```
SELECT   <KW,1>
from_   <IDN,from_>
.   <OP,16>
_1_   <IDN,_1_>
,   <SE,3>
SUM   <KW,21>
(   <SE,1>
from_   <IDN,from_>
.   <OP,16>
_2_   <IDN,_2_>
)   <SE,2>
FROM   <KW,2>
from_   <IDN,from_>
JOIN   <KW,14>
_1A   <IDN,_1A>
ON   <KW,17>
from_   <IDN,from_>
.   <OP,16>
_1_   <IDN,_1_>
=   <OP,1>
_1A   <IDN,_1A>
.   <OP,16>
cr7   <IDN,cr7>
WHERE   <KW,3>
from_   <IDN,from_>
.   <OP,16>
_2_   <IDN,_2_>
>   <OP,2>
1   <INT,1>
AND   <OP,8>
from_   <IDN,from_>
.   <OP,16>
_3_   <IDN,_3_>
<   <OP,3>
3.1415926   <FLOAT,3.1415926>
OR   <OP,10>
1.25   <FLOAT,1.25>
IS   <KW,31>
NOT   <OP,13>
NULL   <KW,32>
GROUP BY   <KW,24>
from_   <IDN,from_>
.   <OP,16>
```

测试3

测试用例

```
SELECT Websites.name, access_log.count, access_log.date
FROM Websites
JOIN access_log
ON Websites.id=access_log.site_id
ORDER BY access_log.count
```

词法分析结果

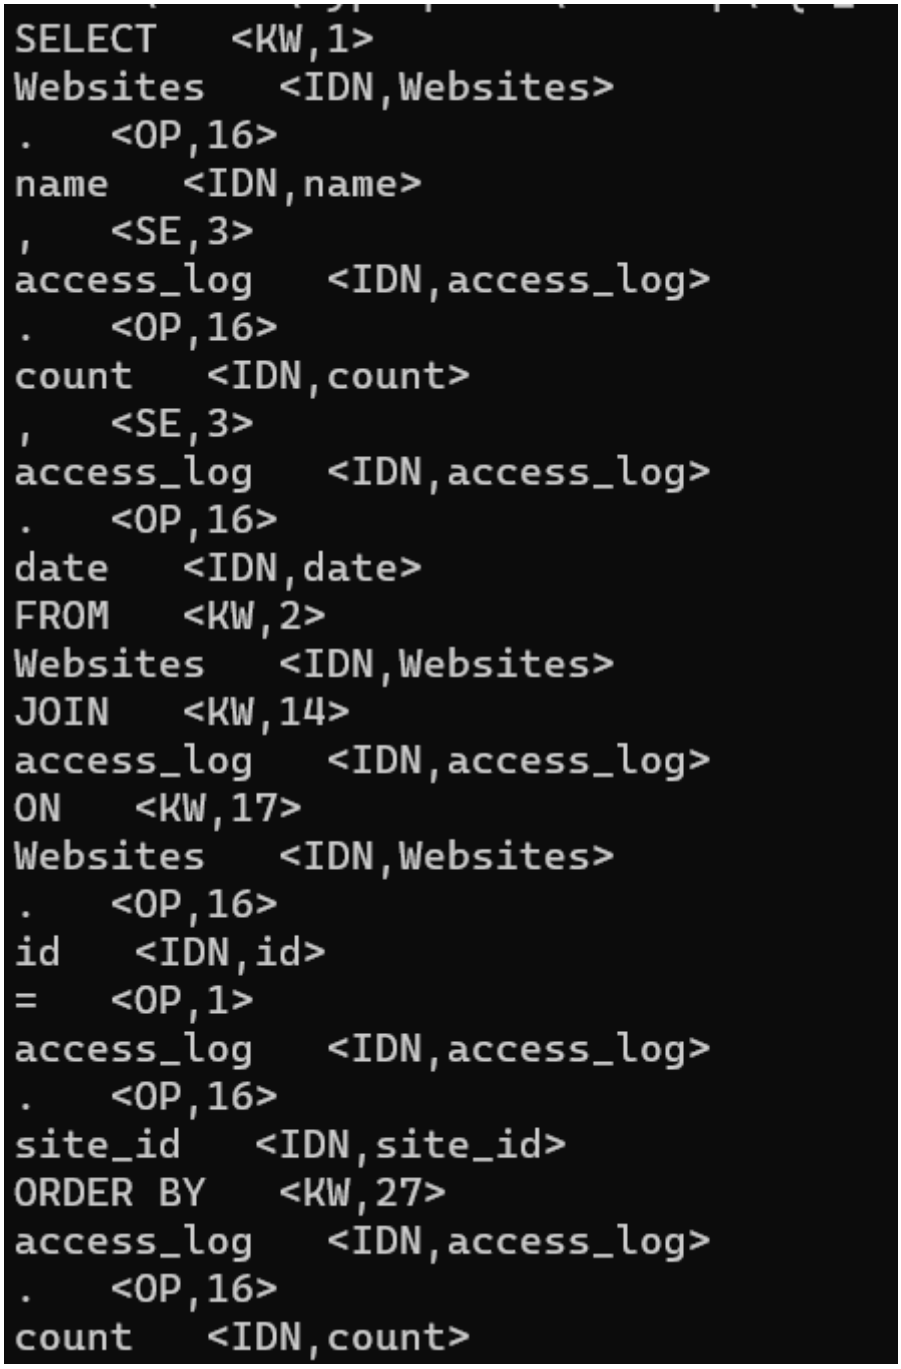

测试4

测试用例

```
SELECT AVG(count) AS CountAverage FROM access_log
```

词法分析结果

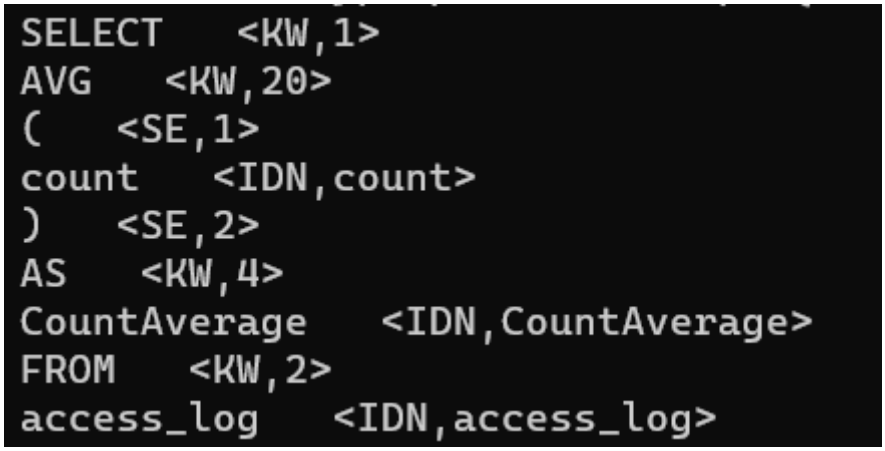

测试5

测试用例

```
SELECT LastName,FirstName,Address FROM Persons
WHERE Address IS NOT NULL
```

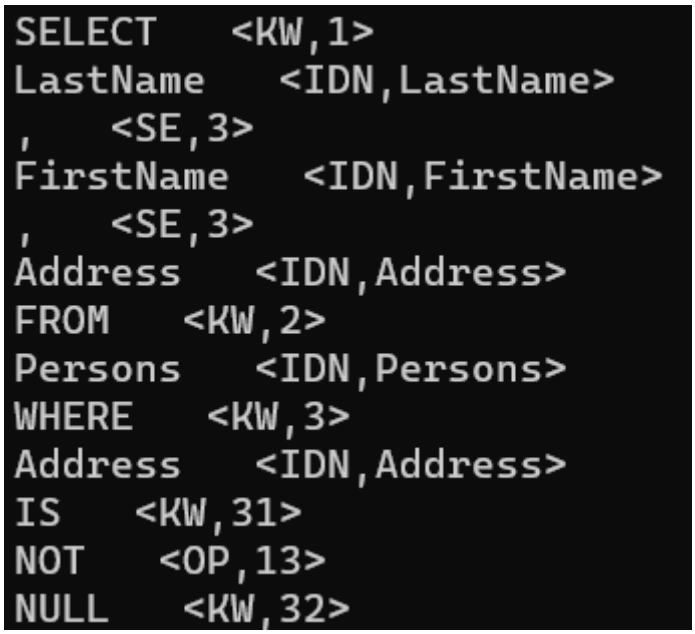

二、语法分析器设计

（一）开发报告

实现LL(1)和LR(1)两种语法分析方法

1 LL(1)

1.1 实现思路

1. 构造**first集**。
2. 构造**follow集**。
3. 根据first集和follow集构造**分析表table**。
4. 构造**符号栈v_stack**和**状态栈state_stack**根据分析表对输入串进行语法分析。

1.2 具体实现

1.2.1 数据结构定义

```
VN = [] # 非终结符集
VT = [] # 终结符集
V = [] # 符号集

rules = [] # 文法规则

first = [] # first集
follow = [] # follow集
table = [] # 分析表

test_str = [] # 输入串
state_stack = [] # 状态栈
v_stack = [] # 符号栈
```

1.2.2 函数定义

```
# 读取sql语法文件
def read_sql_syntax()
# 划分终结符和非终结符
def get_V()

# 检测规则是否为A->$的形式
def in_empty_rule(this_vn)

# 初始化、构造及输出first集
def init_first()
def get_first()
def print_first()
# 初始化、构造及输出follow集
def init_follow()
def get_follow()
def print_follow()
```

```
# 初始化、构造及输出table分析表
def init_table()
def get_table()
def print_table(max_vn_index, max_vt_index)
# 计算符号在符号集中的索引(FLAG = 0 为总符号集；FLAG = 1 为终结符集；FLAG = 2 为非终结符集)

def get_v_index(this_v, FLAG)
#计算语法规则的索引
def get_rule_index(this_rule)
```

1.2.3 main函数

1. 依次调用函数`read_sql_syntax()`读取sql语法、`get_V()`划分终结符集和非终结符集、`get_first()`构造first集、`get_follow()`构造follow集、`get_table`构造table分析表。
2. 输入分析串，例如：

```
SELECT IDN . IDN FROM IDN WHERE IDN . IDN > INT
```

3. 初始化`test_str`分析串（在输入串后加#并进行预处理）。初始化`v_stack`符号栈，即将`# root`进栈。初始化`state_stack`状态栈，即将`0`进栈。
4. 从左依次编历`test_str`分析串，每次取`a = test_str[0]`直至`test_str == None`：

- `a`不是终极符，终止循环，输入串不符合语法规则，输出`error`。
- `a`是终结符，`a`等于`v_stack[-1]`且`a`为`#`，则输入串符合语法规则，输出`accept`。
- `a`是终结符，`a`等于`v_stack[-1]`且`a`不为`#`，则对`a`进行移入，输出`move`。

```
    v_stack.pop()
    test_str.pop(0)
```

- `a`是终结符，`a`不等于`v_stack[-1]`，则查找分析表`table`进行规约，输出`reduction`。注意：所用规约的语法规则`rule`中的`$`不需`push`符号栈。

```
    rule = []
    vt_index = get_v_index(a, 1)
    vn_index = get_v_index(v_stack[-1], 2)
    rule_index = table[vn_index][vt_index]
    rule = rules[rule_index - 1][:]

    if a != '#':
        print("{}\t{}\t{}#{}\treduction".format(step, rule_index, v_stack[-1],
a), file = result)
    else:
        print("{}\t{}\t{}#\treduction".format(step, rule_index, v_stack[-1]),
file = result)
    step = step + 1

    v_stack.pop()
    for i in range(len(rule) - 2):
        tmp = rule[len(rule) - i - 1][:]
        if tmp != '$':
            v_stack.append(tmp)
```

1.2.4 get_first函数

1. 首先调用`init_first`函数初始化`first`集。
2. 编历`rules`规则列表,对每一条规则`rule`以下行规则为例

```
S -> A B C D E
```

- 获得非终结符`S`的索引`vn_index`
- 依次编历`A B C D E`即`->`后的符号，记当前编历符号为`N`。
- 若符号`N`为终结符且不在`S`的`first`集中，则将符号加入`S`的`first`集并退出循环。
- 若符号`N`是非终结符，则将该符号的first集并入`S`的`first`集中。
- 如果该符号`N`不存在规则`N->$`，则退出循环。
- 如果该符号`N`存在规则`N->$`且`N`为规则`rule`的最后一个符号，则将`$`加入`S`的`first`集。

3. 如果所有非终结符的`first`集有所更新，则回到2，直至所有非终结符的`first`集不再改变。

1.2.5 get_follow函数

1. 首先调用`init_follow`函数初始化`follow`集。
2. 编历`rules`规则列表,以下行规则为例

```
S -> A B C D E
```

3. 对每一条规则`rule`:

- 获得非终结符`S`的索引`vn_index`
- 外层依次编历`A B C D`即`->`后的符号（除最后一个符号），记当前编历符号为`N`。
- 内层依次编历`N`即`->`后的符号，记当前编历符号为`M`。
- 若符号`N`为非终结符且`M`为终结符且`M`不在`S`的`follow`集中，则将符号加入`N`的`follow`集并退出内层循环。
- 若符号`N`为非终结符且`M`为非终结符，则将`M`的`follow`集并入`N`的`follow`集中。
- 如果该符号`M`不存在规则`M->$`，则退出内层循环。

4. 对每一条规则`rule`:

- 从倒数第二个符号即`C`开始依次编历`A B C D`即`->`后的符号，记当前编历符号为`N`。
- 如果`N`为非终结符，则将`S`的`follow`集并入`N`的`follow`集中。
- 如果该符号`N`不存在规则`N->$`，则退出循环。

5. 如果所有非终结符的`follow`集有所更新，则回到2，直至所有非终结符的`follow`集不再改变。

1.2.6 get_table函数

get_table伪代码

```
init_table()
for vn in VN:
    for vt in VT:
        for rule in rules:
            以 S -> A B C D为例
            如果vn == S
                1. A是终结符且vt == A
                table[vn_index][vt_index] = rule_index
                2. A是非终结符且vt在S的first集中且vt在A的first集
                table[vn_index][vt_index] = rule_index
```

```
            如果vn != S break
    如果$在vn的first集中且vn的follow集不为空
        编历vn的follow集
            对于vn的follow集每个终结符vt，如果存在规则 vn->$,则
            table[vn_index][follow_vt_index] = rule_index
```

1.3 分析结果

1.3.1 运行语法分析器

1. 输入为`input`下的词法分析器的输出文件
2. 输出保存在`output`文件夹下，命名方式为`13Agra.tsv`。
3. 运行语法分析器LL1命令:

```
cd syntax-analysis
python LL.py
```

1.3.2 运行结果展示

1. 构造`first`集（展示部分）

```
----------------------first-----------------------------
root ['UPDATE', 'DELETE', 'SELECT', '(', 'INSERT']
dmlStatement ['UPDATE', 'DELETE', 'SELECT', '(', 'INSERT']
selectStatement ['SELECT', '(']
unionStatements ['$', 'UNION']
unionStatement ['UNION']
unionStatementKey ['UNION']
unionStatementQuery ['SELECT', '(']
unionType ['ALL', 'DISTINCT', '$']
querySpecification ['SELECT', '(']
selectClause ['$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY']
fromClause ['FROM', '$']
groupByClause ['GROUP BY', '$']
havingClause ['HAVING', '$']
orderByClause ['ORDER BY', '$']
selectElements ['*', 'IDN', 'AVG', 'MAX', 'MIN', 'SUM']
selectElementHead ['*', 'IDN', 'AVG', 'MAX', 'MIN', 'SUM']
selectElementListRec [',', '$']
selectElement ['IDN', 'AVG', 'MAX', 'MIN', 'SUM']
elementNameAlias ['AS', '$', 'IDN']
tableSources ['(', 'IDN']
tableSourceListRec [',', '$']
tableSource ['(', 'IDN']
joinParts ['$', 'JOIN', 'LEFT', 'RIGHT']
tableSourceItem ['(', 'IDN']
tableName ['IDN']
uidList ['IDN']
uidListRec [',', '$']
uid ['IDN']
fullColumnName ['IDN']
dottedId ['.', '$']
```

2. 构造`follow`集（展示部分）

```
----------------------follow-----------------------------
root ['#']
dmlStatement ['#']
selectStatement ['#']
unionStatements ['#']
unionStatement ['$', 'UNION', '#']
unionStatementKey ['SELECT', '(']
unionStatementQuery ['$', 'UNION', '#']
unionType ['SELECT', '(', '*', 'IDN', 'AVG', 'MAX', 'MIN', 'SUM']
querySpecification ['$', 'UNION', '#', ')']
selectClause ['$', 'UNION', '#', ')']
fromClause ['GROUP BY', '$', 'HAVING', 'ORDER BY', 'UNION', '#', ')']
groupByClause ['HAVING', '$', 'ORDER BY', 'UNION', '#', ')']
havingClause ['ORDER BY', '$', 'UNION', '#', ')']
orderByClause ['$', 'UNION', '#', ')']
selectElements ['$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY']
selectElementHead [',', '$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY']
selectElementListRec ['$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY']
selectElement [',', '$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY']
elementNameAlias [',', '$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY', 'JOIN', 'LEFT', 'RIGHT', 'WHERE', 'UNION', '#', 'SET', 'ON', ')
']
tableSources ['WHERE', '$', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', ')']
tableSourceListRec ['WHERE', '$', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', ')']
tableSource [',', '$', 'WHERE', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', ')']
joinParts [',', '$', 'WHERE', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', ')']
tableSourceItem ['$', 'JOIN', 'LEFT', 'RIGHT', ',', 'WHERE', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', 'ON', ')']
tableName ['AS', '$', 'IDN', 'JOIN', 'LEFT', 'RIGHT', ',', 'WHERE', 'GROUP BY', 'HAVING', 'ORDER BY', 'UNION', '#', '(', 'VALUES', 'V
ALUE', 'SET', 'ON', ')']
uidList [')']
uidListRec [')']
uid [',', '$', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY', 'AS', 'IDN', 'JOIN', 'LEFT', 'RIGHT', 'WHERE', 'UNION', '#', '.', 'SET', '('
, 'VALUES', 'VALUE', 'ON', ')', '=', '>', '<', '<=', '>=', '!=', '<=>', 'IS', 'AND', '&&', 'XOR', 'OR', '||']
fullColumnName ['AS', '$', 'IDN', ',', 'FROM', 'GROUP BY', 'HAVING', 'ORDER BY', '=', '>', '<', '<=', '>=', '!=', '<=>', 'IS', 'AND',
 '&&', 'XOR', 'OR', '||', 'UNION', '#', ')', 'JOIN', 'LEFT', 'RIGHT', 'WHERE']
```

3. 构造`table`分析表（展示部分）

```
-------------------------------------------------TABLE-------------------------------------------------
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| VN                  | $   | UNION   | ALL   | DISTINCT   | SELECT   | (   | )   | FROM   | GROUP BY   | HAVING   |
+=====================+=====+=========+=======+============+==========+=====+=====+========+============+==========+
| root                |     |         |       |            | 1        | 1   |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| dmlStatement        |     |         |       |            | 2        | 2   |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| selectStatement     |     |         |       |            | 6        | 6   |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| unionStatements     | 8   | 7       |       |            |          |     |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| unionStatement      |     | 9       |       |            |          |     |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| unionStatementKey   |     | 10      |       |            |          |     |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| unionStatementQuery |     |         |       |            | 11       | 11  |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| unionType           | 14  |         | 12    | 13         | 14       | 14  |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| querySpecification  |     |         |       |            | 15       | 16  |     |        |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
| selectClause        | 17  |         |       |            |          |     |     | 17     |            |          |
+---------------------+-----+---------+-------+------------+----------+-----+-----+--------+------------+----------+
```

4. 输出结果`13Agra.tsv`（展示部分）

```
1   1   root#INSERT reduction
2   3   dmlStatement#INSERT reduction
3   112 insertStatement#INSERT  reduction
4   115 insertKeyword#INSERT    reduction
5   /   INSERT#INSERT   move
6   116 into#INTO   reduction
7   /   INTO#INTO   move
8   44  tableName#IDN   reduction
9   48  uid#IDN reduction
10  /   IDN#IDN move
11  113 insertStatementRight#VALUES reduction
12  118 insertStatementValue#VALUES reduction
13  119 insertFormat#VALUES reduction
14  /   VALUES#VALUES   move
15  /   (#( move
16  123 expressionsWithDefaults#INT reduction
17  127 expressionOrDefault#INT reduction
18  58  expression#INT  reduction
19  72  predicate#INT   reduction
20  75  expressionAtom#INT  reduction
21  80  constant#INT    reduction
22  84  decimalLiteral#INT  reduction
23  /   INT#INT move
24  74  predicateRight#,    reduction
25  61  expressionRight#,   reduction
```

```
26  125 expressionOrDefaultListRec#,    reduction
27  /   ,#, move
28  127 expressionOrDefault#FLOAT   reduction
29  58  expression#FLOAT    reduction
30  72  predicate#FLOAT reduction
31  75  expressionAtom#FLOAT    reduction
32  80  constant#FLOAT  reduction
33  83  decimalLiteral#FLOAT    reduction
34  /   FLOAT#FLOAT move
35  74  predicateRight#,    reduction
36  61  expressionRight#,   reduction
37  125 expressionOrDefaultListRec#,    reduction
38  /   ,#, move
39  127 expressionOrDefault#STRING  reduction
40  58  expression#STRING   reduction
41  72  predicate#STRING    reduction
42  75  expressionAtom#STRING   reduction
43  79  constant#STRING reduction
44  97  stringLiteral#STRING    reduction
45  /   STRING#STRING   move
46  74  predicateRight#)    reduction
47  61  expressionRight#)   reduction
48  126 expressionOrDefaultListRec#)    reduction
49  /   )#) move
50  122 expressionsWithDefaultsListRec# reduction
51  /   #   accept
```

与提供的0Agra.tsv进行比对，程序运行结果正确！

2 LR(1)

2.1 实现思路

1. 构造**first集**
2. 构造**项目集items**
3. 根据项目集通过闭包运算构造**项目集规范族**
4. 根据项目集规范族构造**action表**和**goto表**
5. 构造**符号栈v_stack**和**状态栈state_stack**根据action表和goto表对输入串进行语法分析。

2.2 具体实现

2.2.1 数据结构定义

```
# 规范项目
class Standard_item:
    def __init__(self, left, right):
        self.left = left # 项目
        self.right = right # 向前搜索符串

VN = [] # 非终结符集
VT = [] # 终结符集
V = [] # 符号集

rules = [] # 文法规则
items = [] # 项目集
standard_items = [] # 规范项目集

first = [] # first集

action = [] # action表
goto = [] # goto表

test_str = [] # 输入串
state_stack = [] # 状态栈
v_stack = [] # 符号栈
```

2.2.2 函数定义

```
# 读取sql语法文件
def read_sql_syntax()
# 划分终结符和非终结符
def get_V()

# 检测规则是否为A->$的形式
def in_empty_rule(this_vn)
# 初始化、构造及输出first集
def init_first()
def get_first()
def print_first()

# 构造文法项目
def get_items()
# 闭包运算
def get_closeure(set)
# 检测规范项目it是否在闭包中
def in_closure(it, closure)
# 得到新的规范项目集
def get_new_item(standard_item, v)
# 构造项目集规范族standard_items
def get_standard_items()
# 判断规范项目集new_item是否在项目集规范族standard_items中
def in_standard_items(new_item)

# 初始化、构造及输出action集
def init_action()
def get_action()
def print_action()
# 初始化、构造及输出goto集
```

```
def init_goto()
def get_goto()
def print_goto()

# 计算规范项目集在项目集规范族中的索引
def get_standard_item_index(this_item)
# 计算符号在符号集中的索引(FLAG = 0 为总符号集；FLAG = 1 为终结符集；FLAG = 2 为非终结符集)
def get_v_index(this_v, FLAG)
#计算语法规则的索引
def get_rule_index(this_rule)
```

2.2.3 main函数

1. 依次调用函数`read_sql_syntax()`读取sql语法、`get_V()`划分终结符集和非终结符集、`get_items()`构造文法项目、`get_first()`构造first集、`get_standard_items()`构造项目集规范族、`get_action`构造action分析表、`get_goto`构造goto分析表。
2. 输入分析串，例如：

```
SELECT IDN . IDN FROM IDN WHERE IDN . IDN > INT
```

3. 初始化`test_str`分析串（在输入串后加#并进行预处理）。初始化`v_stack`符号栈，即将`# root`进栈。初始化`state_stack`状态栈，即将`0`进栈。
4. 从左依次编历`test_str`分析串，每次取`a = test_str[0]`直至`test_str == None`：

- `a`不是终极符，终止循环，输入串不符合语法规则，输出`error`。
- `a`是终结符，获取`a`的终结符索引`a_index`,通过`action`分析表得到该执行的动作`act`。

```
    a_index = get_v_index(a, 1)
    act = action[state_stack[-1]][a_index]
```

- 如果`act == 'acc'`，即则输入串符合语法规则，输出`accept`。
- 如果`act[0] == 's'`，即为移进动作，将当前符号`a`进符号栈，将`int(act[1:])`进状态栈，输出`move`。

```
    test_str.pop(0)
    state_stack.append(int(act[1:]))
    print("{}\t/\t{}#{}\tmove".format(step, v_stack[-1], a), file = result)
    v_stack.append(a)
    step = step + 1
```

- 如果`act[0] == 'r'`，即为规约动作，先将状态栈前规约后符号数`len(rules[int(act[1:]) - 1]) - 2`个状态移出，`$`不需将状态移出。将符号栈栈顶移出，将规约后的符号`next_v`进栈。将`next_state = goto[state_stack[-1]][v_index]`进状态栈。

```
    if rules[int(act[1:]) - 1][-1] != '$' or len(rules[int(act[1:]) - 1]) != 3:
        for j in range(len(rules[int(act[1:]) - 1]) - 2):
            state_stack.pop()

    v_stack.pop()
    next_v = rules[int(act[1:]) - 1][0]
    v_stack.append(next_v)
    v_index = get_v_index(v_stack[-1], 2)
    next_state = goto[state_stack[-1]][v_index]
    state_stack.append(next_state)
```

```
    if a != '#':
        print("{}\t{}\t{}#{}\treduction".format(step, int(act[1:]), v_stack[-1],
a), file = result)
    else:
        print("{}\t{}\t{}#\treduction".format(step, int(act[1:]), v_stack[-1]),
file = result)
    step = step + 1
```

- 注意通过A->$规约时，不需要pop状态栈顶
- 通过规则规约时，pop状态栈顶数 = 规约符号数

2.2.4 get_standard_items()函数

函数调用关系

```
get_standard_items()
    |-get_closeure()
    |-in_standard_items()
    |-get_new_item()
        |-get_closeure()
            |-in_closure()
```

1. 通过调用`get_closeure()`函数构造项目集规范族的第一项

```
    set = []
    set.append(Standard_item(items[0], ['#']))
    standard_items.append(get_closeure(set))
```

2. 编历项目集规范族
   对于项目集规范族中的每个项目集`standard_item`，编历符号集`V`，调用`get_new_item(standard_item, v)`函数获得新的项目集，如果新的项目集不为空，且通过`in_standard_items(new_item)`函数判断新的项目集不在项目集规范族中，则将该项目集加入项目集规范族中。

2.2.5 get_action()函数

1. 首先通过`init_action`函数初始化action表
2. 编历项目集规范族，对于项目集规范族中的每个项目集`standard_item`，编历`standard_item`中的所有项目`it`。定义`it_left`为项目，`it_right`为展望符号集，dot_index为it_left.index('`')。

- `it_left[dot_index + 1:] == []`，即项目为"规约"项目
    1. 如果`$`在`it_right`中，则编历终结符集`VT`,`action[item_index][vt_index] == ' '`执行
       `action[item_index][vt_index] = 'r' + str(rule_index)`
    2. 如果`$`在`it_right`中，则只需将`it_right`中的终结符，执行`action[item_index][vt_index] = 'r' + str(rule_index)`
- `it_left[dot_index + 1:] != []`，即项目为"移进"项目。编历终结符集`VT`,如果`vt == it_left[dot_index + 1]`,则执行`action[item_index][vt_index] = 's' + str(next_item_index)`

3. `action[1][len(VT)-1] = 'acc'`，即"接受"，`len(VT)-1`为`#`的索引。

2.2.6 get_goto()函数

1. 首先通过`init_goto`函数初始化goto表
2. 编历项目集规范族，对于项目集规范族中的每个项目集`standard_item`，编历非终结符集`VN`，调用`get_new_item(standard_item, vn)`函数获得新的项目集，如果新的项目集不为空，且通过`in_standard_items(new_item)`函数判断新的项目集不在项目集规范族中，则`goto[item_index][vn_index] = next_item_index`。

2.3 分析结果

2.3.1 运行语法分析器

1. 输入为`input`下的词法分析器的输出文件
2. 输出保存在`output`文件夹下，命名方式为`13Agra.tsv`。
3. 运行语法分析器LL1命令:

```
cd syntax-analysis
python LL.py
```

2.3.2 运行结果展示

1. 构造`action`集（展示部分）

ACTION

state	$	UNION	ALL	DISTINCT	SELECT	(	)	FROM	GROUP BY	HAVING
0					s9	s10				
1										
2										
3										
4		s17								
5										
6										
7										
8										
9			s22	s23						

2. 构造`goto`集（展示部分）

GOTO

state	root	dmlStatement	selectStatement	unionStatements	unionStatement	unionStatementKey
0	1	2	3			
1						
2						
3						
4				14	15	16
5						
6						
7						
8						
9						

3. 输出结果`13Bgra.tsv`（展示部分）

```
1   /   ##SELECT    move
2   14  unionType#IDN   reduction
3   /   unionType#IDN   move
4   48  uid#.   reduction
5   /   uid#.   move
6   /   .#IDN   move
7   48  uid#,   reduction
8   52  dottedIdOrStar#,    reduction
9   50  dottedId#,  reduction
10  49  fullColumnName#,    reduction
11  35  elementNameAlias#,  reduction
12  31  selectElement#, reduction
13  28  selectElementHead#, reduction
14  /   selectElementHead#, move
15  /   ,#SUM   move
16  105 function#(  reduction
17  /   function#(  move
18  14  unionType#IDN   reduction
19  /   unionType#IDN   move
20  48  uid#.   reduction
21  /   uid#.   move
22  /   .#IDN   move
23  48  uid#)   reduction
24  52  dottedIdOrStar#)    reduction
25  50  dottedId#)  reduction
26  49  fullColumnName#)    reduction
27  /   fullColumnName#)    move
28  101 aggregateWindowedFunction#FROM  reduction
29  100 functionCall#FROM   reduction
```

```
164 /   uid#.   move
165 /   .#IDN   move
166 48  uid#=   reduction
167 52  dottedIdOrStar#=    reduction
168 50  dottedId#=  reduction
169 49  fullColumnName#=    reduction
170 76  expressionAtom#=    reduction
171 /   expressionAtom#=    move
172 85  comparisonOperator#STRING   reduction
173 /   comparisonOperator#STRING   move
174 97  stringLiteral#  reduction
175 79  constant#   reduction
176 75  expressionAtom# reduction
177 74  predicateRight# reduction
178 72  predicate#  reduction
179 73  predicateRight# reduction
180 72  predicate#  reduction
181 61  expressionRight#    reduction
182 58  expression# reduction
183 22  havingClause#   reduction
184 25  orderByClause#  reduction
185 17  selectClause#   reduction
186 15  querySpecification# reduction
187 8   unionStatements#    reduction
188 6   selectStatement#    reduction
189 2   dmlStatement#   reduction
190 1   root#   reduction
191 1   root#   accept
```

（二）测试报告

测试1

1.1 输入

词法分析器给出的测试用例为此代码：

```
INSERT INTO _tb1 VALUES (1,1.78,"SELECT")
```

经过词法分析器的分析后，我们得到了以下Token序列作为语法分析器的输入用例，

```
INSERT  <KW,6>
INTO    <KW,7>
_tb1    <IDN,_tb1>
VALUES  <KW,8>
(   <SE,1>
1   <INT,1>
,   <SE,3>
1.78    <FLOAT,1.78>
,   <SE,3>
"SELECT"    <STRING,SELECT>
)   <SE,2>
```

输入文法为：sql_syntax.txt文件

1.2 输出

输出结果为

```
1   1   root#INSERT reduction
2   3   dmlStatement#INSERT reduction
3   112 insertStatement#INSERT  reduction
4   115 insertKeyword#INSERT    reduction
5   /   INSERT#INSERT   move
6   116 into#INTO   reduction
7   /   INTO#INTO   move
8   44  tableName#IDN   reduction
9   48  uid#IDN reduction
10  /   IDN#IDN move
11  113 insertStatementRight#VALUES reduction
12  118 insertStatementValue#VALUES reduction
13  119 insertFormat#VALUES reduction
14  /   VALUES#VALUES   move
15  /   (#( move
16  123 expressionsWithDefaults#INT reduction
17  127 expressionOrDefault#INT reduction
18  58  expression#INT  reduction
19  72  predicate#INT   reduction
20  75  expressionAtom#INT  reduction
21  80  constant#INT    reduction
22  84  decimalLiteral#INT  reduction
23  /   INT#INT move
24  74  predicateRight#,    reduction
25  61  expressionRight#,   reduction
26  125 expressionOrDefaultListRec#,    reduction
27  /   ,#, move
28  127 expressionOrDefault#FLOAT   reduction
```

```
29  58  expression#FLOAT    reduction
30  72  predicate#FLOAT reduction
31  75  expressionAtom#FLOAT    reduction
32  80  constant#FLOAT  reduction
33  83  decimalLiteral#FLOAT    reduction
34  /   FLOAT#FLOAT move
35  74  predicateRight#,    reduction
36  61  expressionRight#,   reduction
37  125 expressionOrDefaultListRec#,    reduction
38  /   ,#, move
39  127 expressionOrDefault#STRING  reduction
40  58  expression#STRING   reduction
41  72  predicate#STRING    reduction
42  75  expressionAtom#STRING   reduction
43  79  constant#STRING reduction
44  97  stringLiteral#STRING    reduction
45  /   STRING#STRING   move
46  74  predicateRight#)    reduction
47  61  expressionRight#)   reduction
48  126 expressionOrDefaultListRec#)    reduction
49  /   )#) move
50  122 expressionsWithDefaultsListRec# reduction
51  /   #   accept
```

展示截图如下：

```
1   1   root#INSERT reduction
2   3   dmlStatement#INSERT reduction
3   112 insertStatement#INSERT  reduction
4   115 insertKeyword#INSERT    reduction
5   /   INSERT#INSERT   move
6   116 into#INTO   reduction
7   /   INTO#INTO   move
8   44  tableName#IDN   reduction
9   48  uid#IDN reduction
10  /   IDN#IDN move
11  113 insertStatementRight#VALUES reduction
12  118 insertStatementValue#VALUES reduction
13  119 insertFormat#VALUES reduction
14  /   VALUES#VALUES   move
15  /   (#( move
16  123 expressionsWithDefaults#INT reduction
17  127 expressionOrDefault#INT reduction
18  58  expression#INT  reduction
19  72  predicate#INT   reduction
20  75  expressionAtom#INT  reduction
21  80  constant#INT    reduction
22  84  decimalLiteral#INT  reduction
23  /   INT#INT move
24  74  predicateRight#,    reduction
25  61  expressionRight#,   reduction
26  125 expressionOrDefaultListRec#,    reduction
27  /   ,#, move
28  127 expressionOrDefault#FLOAT   reduction
29  58  expression#FLOAT    reduction
30  72  predicate#FLOAT reduction
31  75  expressionAtom#FLOAT    reduction
32  80  constant#FLOAT  reduction
```

测试2

2.1 输入

词法分析器给出的测试用例为此代码：

```
SELECT from_._1_,SUM(from_._2_) FROM from_ JOIN _1A ON from_._1_=_1A.cr7 WHERE
from_._2_>1 AND from_._3_<3.1415926 OR 1.25 IS NOT NULL GROUP BY from_._2_
HAVING from_._3_="ORDER BY #><=="
```

经过词法分析器的分析后，我们得到了以下Token序列作为语法分析器的输入用例，

```
SELECT  <KW,1>
from_   <IDN,from_>
.   <OP,16>
```

```
_1_ <IDN,_1_>
,   <SE,3>
SUM <KW,21>
(   <SE,1>
from_   <IDN,from_>
.   <OP,16>
_2_ <IDN,_2_>
)   <SE,2>
FROM    <KW,2>
from_   <IDN,from_>
JOIN    <KW,14>
_1A <IDN,_1A>
ON  <KW,17>
from_   <IDN,from_>
.   <OP,16>
_1_ <IDN,_1_>
=   <OP,1>
_1A <IDN,_1A>
.   <OP,16>
cr7 <IDN,cr7>
WHERE   <KW,3>
from_   <IDN,from_>
.   <OP,16>
_2_ <IDN,_2_>
>   <OP,2>
1   <INT,1>
AND <OP,8>
from_   <IDN,from_>
.   <OP,16>
_3_ <IDN,_3_>
<   <OP,3>
3.1415926   <FLOAT,3.1415926>
OR  <OP,10>
1.25    <FLOAT,1.25>
IS  <KW,31>
NOT <OP,13>
NULL    <KW,32>
GROUP BY    <KW,24>
from_   <IDN,from_>
.   <OP,16>
_2_ <IDN,_2_>
HAVING  <KW,25>
from_   <IDN,from_>
.   <OP,16>
_3_ <IDN,_3_>
=   <OP,1>
"ORDER BY #><=="    <STRING,ORDER BY #><==>
```

2.2 输出

由于此部分所占篇幅较大，无法在代码块中展示，故用截图代替（展示部分）

```
1   /   ##SELECT    move
2   14  unionType#IDN   reduction
3   /   unionType#IDN   move
4   48  uid#.   reduction
5   /   uid#.   move
6   /   .#IDN   move
7   48  uid#,   reduction
8   52  dottedIdOrStar#,    reduction
9   50  dottedId#,  reduction
10  49  fullColumnName#,    reduction
11  35  elementNameAlias#,  reduction
12  31  selectElement#, reduction
13  28  selectElementHead#, reduction
14  /   selectElementHead#, move
15  /   ,#SUM   move
16  105 function#(  reduction
17  /   function#(  move
18  14  unionType#IDN   reduction
19  /   unionType#IDN   move
20  48  uid#.   reduction
21  /   uid#.   move
22  /   .#IDN   move
23  48  uid#)   reduction
24  52  dottedIdOrStar#)    reduction
25  50  dottedId#)  reduction
26  49  fullColumnName#)    reduction
27  /   fullColumnName#)    move
28  101 aggregateWindowedFunction#FROM  reduction
29  100 functionCall#FROM   reduction
30  35  elementNameAlias#FROM   reduction
31  32  selectElement#FROM  reduction
32  30  selectElementListRec#FROM   reduction
33  29  selectElementListRec#FROM   reduction
34  26  selectElements#FROM reduction
35  /   selectElements#FROM move
36  /   FROM#IDN    move
37  48  uid#JOIN    reduction
38  44  tableName#JOIN  reduction
39  35  elementNameAlias#JOIN   reduction
40  42  tableSourceItem#JOIN    reduction
41  /   tableSourceItem#JOIN    move
42  /   JOIN#IDN    move
43  48  uid#ON  reduction
44  44  tableName#ON    reduction
45  35  elementNameAlias#ON reduction
46  42  tableSourceItem#ON  reduction
47  /   tableSourceItem#ON  move
48  /   ON#IDN  move
49  48  uid#.   reduction
```

```
50  /   uid#.   move
51  /   .#IDN   move
52  48  uid#=   reduction
53  52  dottedIdOrStar#=    reduction
54  50  dottedId#=  reduction
55  49  fullColumnName#=    reduction
56  76  expressionAtom#=    reduction
57  /   expressionAtom#=    move
58  85  comparisonOperator#IDN  reduction
59  /   comparisonOperator#IDN  move
60  48  uid#.   reduction
61  /   uid#.   move
62  /   .#IDN   move
63  48  uid#WHERE   reduction
64  52  dottedIdOrStar#WHERE    reduction
65  50  dottedId#WHERE  reduction
66  49  fullColumnName#WHERE    reduction
67  76  expressionAtom#WHERE    reduction
68  74  predicateRight#WHERE    reduction
69  72  predicate#WHERE reduction
70  73  predicateRight#WHERE    reduction
71  72  predicate#WHERE reduction
72  61  expressionRight#WHERE   reduction
73  58  expression#WHERE    reduction
74  108 joinRightPart#WHERE reduction
75  106 joinPart#WHERE  reduction
76  41  joinParts#WHERE reduction
77  40  joinParts#WHERE reduction
78  39  tableSource#WHERE   reduction
```